

정형, 비정형 데이터

정형 : 스키마가 미리 정해져 있고 표(행열)에 딱 맞는 데이터

비정형 : 정해진 형식 없이 원본 그대로 존재하는 데이터

1. 정형 데이터 (Structured Data)

정의

- 형식이 미리 정해져 있어 행과 열로 이루어진 표에 맞게 저장되는 데이터

특징

- 사전 정의된 형식: 새로 추가되는 레코드도 같은 형식을 따름
- 동일한 속성: 모든 레코드가 같은 속성을 가짐 (예: 예약 기록 → 예약자명, 이벤트명, 날짜, 금액)
- 분석 친화적: 균일하게 정리되어 있어 집계, 수치 연산에 유리
- 관계형: 공통 키로 여러 테이블을 연결
- 저장: 관계형 DB에 저장하고 SQL로 관리

예시

- 엑셀 스프레드시트, SQL/관계형 데이터베이스

장점

- 사용 편의: 조회, 수정 같은 일상 작업이 쉽고, 고정 길이 타입(CHAR, INT, DATE)으로 저장 효율이 높음
- 분석: SQL, 머신러닝으로 패턴 도출이 쉬움
- 보안: 행열 단위의 세밀한 접근 제어 가능
- 백업 가능: 데이터가 언제 어떻게 수집, 변경, 이동 됐는지 이력 추적 가능

한계

- 가격, 주문량은 잘 담지만 고객 감정 같은 맥락은 못 담음
- 필드 추가나 관계 변경 시 스키마 자체를 수정해야 해서 비용, 리스크가 큼
- 테이블 간 관계가 많아지면 쿼리가 매우 복잡해짐

- 현실 데이터를 정해진 구조에 맞추기 어려움
-

2. 비정형 데이터 (Unstructured Data)

정의

- 정해진 스키마 없이 텍스트, 이미지, 영상 등 원본 형태 그대로 존재해 표에 담기 어려운 데이터

특징

- 스키마 없음: 형식이 제각각이라 기존 관계형 DB의 고정된 구조를 따르지 않음
- 방대한 규모: 기업이 생성하는 데이터의 약 90%를 차지하며, 메시지·사진·센서 신호마다 계속 늘어남
- 주로 정성적 정보: 수치보다 감정, 의견, 맥락 같은 정보를 담음
- 원본 형식 그대로 저장
 - 오브젝트 스토리지: 데이터 + 메타데이터 + 고유 ID를 하나의 객체로 저장 (예: Amazon S3)
 - 데이터 레이크: 모든 형식의 원본 데이터를 대량 저장, 구조는 분석할 때 결정
 - 데이터 레이크하우스: 레이크의 유연성 + 웨어하우스의 분석 성능을 결합한 차세대 구조
 - NoSQL DB: 스키마 없이 저장, 속도, 확장성 우수
 - 기타: 파일 시스템, 디지털 자산 관리(DAM), 콘텐츠 관리 시스템(CMS), 버전 관리 시스템
- 고급 분석 기술 필요
 - 분석 기법: 머신러닝, NLP, 텍스트 마이닝, 이미지 인식, 감정 분석
 - 대부분 분석 전에 전처리(정형, 반정형 형태로 추출)가 필요

예시

- 텍스트: 이메일, Word, PDF, 블로그, SNS 게시물, 통화 녹취록 등
- 비텍스트: 이미지(JPEG, PNG, GIF), 오디오, 비디오, 스캔 문서, 모바일 활동 데이터, IoT 센서 데이터

장점

- 정형 데이터가 못 담는 고객 감정, 의견, 맥락까지 파악 가능
- 스키마를 미리 설계하지 않아도 바로 저장할 수 있고, 새로운 형식도 쉽게 추가
- 오브젝트 스토리지, 데이터 레이크로 거의 무제한 확장
- 예전엔 활용이 어려운 다크 데이터였지만, 지금은 AI 활용의 기반
 - 생성형 AI 학습: 라벨 없는 대량의 다양한 데이터로 파운데이션 모델 학습
 - 고객 행동, 감정 분석: 리뷰, SNS 텍스트로 긍정/부정/중립 판별
 - 챗봇 텍스트 분석: 대화 로그로 고객 행동 파악, 챗봇 성능 개선

한계

- 저장 부담: 용량이 커서 비용, 공간, 자원이 더 많이 듦
- 분석 난이도: 복잡한 알고리즘이 필요하고, 검증된 도구가 정형 데이터보다 적음
- 검색 어려움: 정해진 규칙이 없어 기존 방식으로는 원하는 정보를 찾기 힘들
- 관리 부담: 관리 없이 쌓기만 하면 "데이터 늪"이 됨.
AI에 쓰기 전 분류, 품질 평가, 개인정보 필터링, 중복 제거가 필요

3. 적합한 경우

- 정형 데이터가 적합한 경우
 - 숫자 중심 데이터: 재무, 판매, 마케팅 수치, 과학 모델링
 - 짧은 텍스트, 숫자 필드가 여러 개인 레코드: 인사 기록, 재고 목록, 주택 정보
- 비정형 데이터가 적합한 경우
 - 정형 형식에 안 맞는 기록: CCTV 영상, 사내 문서, SNS 게시물
 - 구조화가 비효율적인 데이터: IoT 센서, 시스템 로그, 채팅 기록

출처

IBM – 비정형 데이터란 무엇인가요?

AWS – What is Structured Data?

AWS – 정형 데이터와 비정형 데이터의 차이점